01

概念白皮书 · 可视化简报

移动端开源模型推理基础软件

统一运行时、类小程序生态、异构模型调度（LLM / Diffusion / VLM / 小模型）。目标：让「调模型」像调用系统服务一样可预期、可组合、可治理。

端侧	平台	生态
隐私 · 离线 · 低延迟	调度 · 资源 · 观测	第三方智能小程序

SSD-inference · 全文见 docs/mobile-ai-runtime-whitepaper.md

EXECUTIVE SUMMARY

摘要：我们要造什么？

- **推理基础软件**：在终端提供开源模型的统一加载、执行与观测层，屏蔽 CPU/GPU/NPU 差异，沉淀内存与线程策略。
- **类小程序容器**：第三方交付轻量包（UI + 逻辑 + manifest），通过稳定 Bridge 调用模型能力与受限系统能力，支持热更新与权限审计。
- **异构调度**：同一设备上共存 LLM、扩散、VLM 与传统小模型，按会话、优先级与热/电量状态做队列与降级，避免「大模型一跑，全场卡顿」。
- **生态接口**：模型以「能力」注册（schema、SLA、许可证），应用以依赖声明消费，便于评测、合规与版本兼容矩阵。

价值闭环

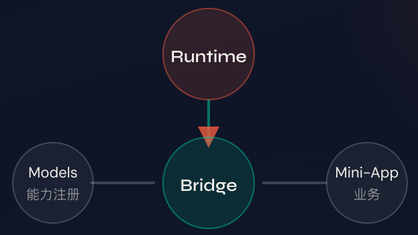

运行时负责「算力与内存」，Bridge 负责「稳定 ABI」，小程序专注交互与编排。

PROBLEM SPACE

背景与动机：为何需要这层软件?

端侧趋势
隐私合规、弱网离线、交互延迟敏感；开源权重与端侧引擎可用性快速提升，但**工程集成高度碎片化**。

开发者成本
每个 App 重复实现加载/量化路径、内存预算、前后处理与回退策略；**跨模态 API 不一致**导致业务代码难以复用。

生态缺口
缺少类似小程序的**标准化沙箱与分发机制**，模型能力难以像服务一样被第三方安全组合。

研究价值
统一调度框架下可量化研究**异构共存、动态路由、能耗–质量 Pareto**，而非一次性 Demo。

碎片化示意 · 多应用 × 多模型组合爆炸

缺少共享运行时 → 重复打包、重复优化、行为不一致。

- **结论**：需要「操作系统式」的端侧 AI 基座：把共性沉到底层，把创新留给上层小程序。
- **边界**：不追求单一模型 SOTA；强调**可插拔、可观测、可治理**与多模型协同。

POSITIONING

愿景与利益相关方

愿景：成为移动端开源智能应用的**默认运行时底座**——开发者主要编写业务与交互，平台处理算力、并发与合规钩子。

终端用户
默认本地推理与显式外传同意；可预期延迟与功耗；多应用间体验一致。

应用开发者
统一 Bridge 与调试探针；专注 manifest 与 UI；减少底层推理排障时间。

模型社区
标准包与基准入口；许可证与能力元数据可读；促进复用而非 Fork 碎片化。

平台 / 系统
算力预算、热管理、权限审计与遥测（可匿名）；为 OEM 集成预留策略接口。

非目标：不替代完整移动 OS；初期不承诺覆盖全部芯片后端，以适配器插件演进。

BUILDING BLOCKS

核心概念：五块拼图

推理 Runtime
进程/服务内统一线程池、内存池与后端选择；暴露会话与取消语义。

Model-as-Capability
输入输出 schema、时延档、显存档、版本与许可证绑定。

智能小程序
沙箱 UI + 脚本；manifest 声明模型依赖与权限白名单。

统一调度器
多队列、抢占、投机解码路由、热/电量感知降级。

工具链
打包、签名校验、基准测试、许可证扫描与 CI 模板。

ARCHITECTURE

逻辑分层：稳定 API，可插拔后端

- **L5** 智能小程序 / 第三方 SDK · UI · manifest
- Bridge API · 稳定 ABI / IDL
- **L4** 应用框架：权限 · 生命周期 · 包管理 · 沙箱
- **L3** 能力编排：多模态管线 · 会话 · 工具调用适配
- **L2** 推理调度：队列 · 优先级 · 批处理 · 降级策略
- **L1** 模型运行时：LLM · Diffusion · VLM · 传统小模型
- **L0** 硬件抽象：CPU / GPU / NPU · 内存池 · 量化编译

设计原则

- **向上稳定**：Bridge 长期兼容；内部实现可换。
- **策略可插拔**：调度与降级以策略包形式下发。
- **观测优先**：延迟/显存/功耗 trace 一等公民。

策略与编排（可变）

调度与资源（中等变更）

HAL / 后端插件（迭代频繁）

MODEL FAMILIES

LLM 与扩散：两类「重任务」如何共处?

大语言模型

- 自回归解码对显存与带宽敏感；利用**前缀 KV 复用**与会话级公平。
- 交互式请求可打断后台摘要；支持投机解码若后端允许。
- 端侧以中小参数 + 强量化为主；超大模型走**可配置云端回退**与隐私脱敏。

图示：交互式负载占比（示例）

扩散模型

- 多步迭代：暴露**步数自适应**与提前终止，映射质量–时间曲线。
- 与 LLM **错峰调度**，避免与 VLM 同事抢占显存峰值。
- 产品层：进度、取消、缩略预览，保证可感知响应。

步数 → 质量收益递减：调度器可在此切分

MULTIMODAL & TINY ML

VLM 与传统小模型：感知与门控

视觉-语言模型

- 视觉编码器往往决定首包延迟：提供**分辨率档位**与「先小图后大图」策略。
- 与相机/相册 IO 并行：预读、降采样与缓存帧。
- 隐私：本地默认；上传需显式声明与最小必要原则。

相机帧 → 降采样 → VLM → 结构化输出

专用小模型

- 低延迟判别：检测、关键词、唤醒、轻量 ASR 等。
- 作为**路由门控**：先判场景/意图，再决定是否唤醒大模型。
- 调度上通常标记为**高优先级短任务**，避免被生成式任务饿死。

小模型 ⇢ 大模型（按需）

SCHEDULER

统一调度：把「并发」变成可策略化的问题

- **全局预算**：随温度、电量与插电状态收紧并发与 batch。
- **任务分类**：交互式 / 后台 / 生成式（可取消）——不同 SLA。
- **跨模型 DAG**：检测 → 裁剪 → VLM → LLM 总结；节点级超时与替代路径。
- **降级路径**：备用小模型、降分辨率/步数/上下文；可解释地反馈给 UI。

示例流水线

调度器在 DAG 边上加超时、重试与替代算子，避免单点拖垮整条链路。

DEVELOPER EXPERIENCE

「类小程序」开发者模型

- **交付物**：manifest（模型依赖、最低算力档、权限声明）+ 前端资源 + 业务脚本。
- **推理 API**：以能力 ID 调用，输入输出符合注册 schema；支持流式与取消令牌。
- **系统 API**：存储、受控网络、相机等——默认最小授权，宿主可策略收紧。
- **嵌入形态**：宿主 App 集成 SDK；后期可选独立启动器聚合多小程序。

```
{
  "appId": "demo.smartcards",
  "models": ["llm.q4_7b", "vlm.s"],
  "minTier": "8GB",
  "permissions": ["camera", "storage.app"]
}
```

manifest 驱动测试与兼容矩阵生成（设备 × 后端 × 版本）。

TRUST

安全、隐私与供应链

- **沙箱**：文件/网络/敏感 API 默认关闭；宿主策略可统一审计。
- **数据驻留**：默认本地推理；任何上传需二次确认与用途说明。
- **模型供应链**：签名、哈希、SBOM；构建可重现与漏洞响应流程。
- **内容安全**：生成式输出策略（年龄模式、企业关键词）由宿主配置。

分层防护示意

策略与合规钩子（宿主 / 企业 MDM）

沙箱与权限中介（Bridge）

模型完整性与许可证校验（运行时）

把「能跑」升级为「可证明地安全默认」。

LANDSCAPE

与常见形态的差异

	形态	与本方案关系
📱	单 App 内嵌模型	强调单团队交付；我们强调**平台化 + 第三方小程序**与统一观测。
⚙️	MLC / llama.cpp 等引擎	优秀的推理后端；可作为 **HAL 插件**，而非完整生态层。
☁️	云函数 + 小程序	算力在云端；我们聚焦**端侧调度、隐私与弱网**，云为可选回退。
🤖	系统级助手	深度 OS 集成；我们可先 **App 级落地**，验证后再谈系统扩展。

ROADMAP

技术路线：验证 → 平台 → 生态

A 验证期（3–6 月）
单平台（建议 Android）；接入 LLM + 小模型；打通 Bridge 与示例小程序；发布模型包格式 v0.1 与基线评测。

B 平台期
Diffusion / VLM 适配器；多队列抢占与更细粒度遥测；开发者工具链（模拟器、剖析、合规扫描）与 RFC 流程。

C 生态期
模型注册表与可选应用分发形态；跨 App 互操作规范；iOS / 策略限制单独评估。

RISKS

风险与应对（简表）

算力/内存瓶颈	→	分级模型 · 动态降级 · 云回退
多后端维护	→	适配器接口稳定 · 优先复用社区引擎
生态冷启动	→	官方示例 · 种子模型 · 学术合作
合规与许可证	→	自动化扫描 · 运行时提示与阻断策略

OPEN & METRICS

开源治理与可量化成功标准

- **许可证**：Runtime 采用 Apache-2.0/MIT 等宽松协议；模型权重遵循上游。
- **治理**：RFC 重大变更；SemVer；安全公告渠道。
- **学术产出**：调度策略、异构共存、端侧 QoS、能耗–质量权衡等可发表系统性结果。

KPI 示例

≤ N 人日
第三方完成首个演示小程序（含调试）

P95 ↓ X%
混合负载下相对「无调度」基线

崩溃率 / 峰值内存
低于阈值；关键路径全链路 tracing

结语

把开源模型从「每个 App 各自集成」推进为**可运营的平台层**：统一调度、统一观测、统一生态接口。 智能小程序承载业务创新，运行时承载算力与信任。

Runtime + Bridge + Mini-App → 可持续生态

完整论述见 docs/mobile-ai-runtime-whitepaper.md